Patrones temporales, formas reportadas y pronóstico del volumen de reportes de fenómenos aéreos no identificados (NUFORC, 2010–2016): un análisis exploratorio con CRISP-DM

Mariana Machado, María José Dangon, Daniel Pallares, Samuel Granados y Sara Vélez

Facultad de Ingeniería, Universidad de La Sabana

9336 – Análisis Exploratorio de Datos

Yenny Paola Sierra Bonilla

10 de noviembre de 2026

Resumen

Este trabajo analiza 50.000 reportes ciudadanos de fenómenos aéreos no identificados (UAP) recibidos por el National UFO Reporting Center entre 2010 y 2016. Como no se tuvo acceso a los objetivos reales de esa organización, los objetivos de negocio se plantearon como supuestos: los de un centro de recepción hipotético que debe asignar analistas según la carga esperada. Siguiendo la metodología CRISP-DM, se documentó la fuente, se diagnosticó la calidad de los datos y se realizó un análisis exploratorio. Los reportes se concentran de noche (61,8 % entre las 19:00 y las 23:00), con un pico estacional en julio (2,4 veces febrero) y una tendencia creciente hasta 2014 seguida de un descenso. La forma declarada se asocia débilmente con la franja horaria (V de Cramér = 0,136) y con la duración ($\eta^2_H = 0{,}018$). Los 4 de julio concentran seis de los siete mayores picos diarios, con más reportes de *fireball*. Como las demás variables se relacionan débilmente, el modelo central fue un pronóstico de series de tiempo del volumen mensual: se compararon un ingenuo estacional, SARIMA, Holt-Winters y un bosque aleatorio, con entrenamiento en 2010–2015 y prueba en 2016. Holt-Winters aditivo sin tendencia obtuvo un MAPE de 17,2 % y redujo el error absoluto medio 6,6 % frente a la referencia: cumple el umbral de error, pero no el de mejora. Se discuten las limitaciones: reportes voluntarios, concentración en Estados Unidos y objetivos de negocio supuestos.

Palabras clave: fenómenos aéreos no identificados, análisis exploratorio de datos, CRISP-DM, series de tiempo, pronóstico de demanda

Patrones temporales, formas reportadas y pronóstico del volumen de reportes de fenómenos aéreos no identificados (NUFORC, 2010–2016): un análisis exploratorio con CRISP-DM

Introducción

Durante décadas, los reportes de objetos voladores no identificados se trataron como un tema marginal. Esa situación cambió cuando la Oficina del Director de Inteligencia Nacional de Estados Unidos (Office of the Director of National Intelligence [ODNI], 2021) y la NASA (National Aeronautics and Space Administration [NASA], 2023) publicaron evaluaciones oficiales sobre fenómenos aéreos no identificados (UAP). Ambos documentos coinciden en que la principal limitación para comprender estos fenómenos no es la ausencia de observaciones, sino la falta de datos sistemáticos, estandarizados y bien gestionados. En ese contexto, los centros que reciben reportes ciudadanos cumplen un papel de primera línea: deben recibir, depurar y clasificar miles de reportes con un equipo limitado de analistas.

Este trabajo adopta, como *supuesto de partida*, la perspectiva de un centro de recepción de reportes hipotético que necesita anticipar cuántos reportes recibirá y en qué momentos, con el fin de asignar analistas de forma eficiente. No se tuvo acceso a los objetivos reales del National UFO Reporting Center (NUFORC) ni de otra organización que registre estos reportes; por eso los objetivos de negocio son supuestos del equipo y se declaran como tales a lo largo del documento. El análisis se organiza según la metodología CRISP-DM (Chapman et al., 2000), que estructura los proyectos de analítica en seis fases: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. El presente documento desarrolla cada fase y concluye con la respuesta a las preguntas de análisis planteadas.

Fase 1: Comprensión del negocio

Temática y pertinencia

El proyecto estudia el comportamiento del proceso de reporte de UAP y no el origen de los fenómenos observados. La unidad de interés es el reporte: cuándo se produce, desde dónde, qué forma y qué duración declara quien lo envía. Esta delimitación es pertinente por dos razones. En primer lugar, la carga de trabajo de un centro de recepción depende directamente del volumen de reportes, que varía según el calendario, y un error de planeación se traduce en analistas ociosos o en reportes sin revisar. En segundo lugar, ODNI (2021) y NASA (2023) señalan la gestión de los datos de reporte como el principal obstáculo para el estudio científico del tema, de modo que caracterizar este proceso aporta a una discusión de interés público. Como los objetivos operativos de NUFORC no son accesibles para el equipo, la carga de trabajo de un centro de recepción se toma como un escenario supuesto, no como un requisito real de la organización.

Objetivos de negocio y objetivos analíticos

La Tabla 1 relaciona cada objetivo de negocio (supuesto) con el objetivo analítico que lo operacionaliza, la pregunta de análisis correspondiente y la técnica prevista.

Tabla 1

Objetivos de negocio, objetivos analíticos y técnicas previstas

Objetivo de negocio (supuesto)	Objetivo analítico	Pregunta	Técnica
ON1. Asignar analistas según la carga esperada en cada periodo	Describir la variación del volumen por año, mes, día de la semana y hora	P1	Análisis temporal; mapa de calor hora × día
ON2. Priorizar y clasificar los reportes entrantes	Caracterizar las formas y su relación con la duración y la hora	P2	Kruskal-Wallis; χ^2 y V de Cramér
ON3. Planear la capacidad con anticipación	Pronosticar el volumen mensual y semanal de reportes	P3	Ingenuo estacional; SARIMA u Holt-Winters; Random Forest
ON4. Prepararse para los días de alta demanda	Verificar picos en festivos con pirotecnia	H1	Mann-Whitney; χ^2; razón de momios

Nota. P = pregunta de análisis; H = hipótesis. Los objetivos de negocio son supuestos del equipo, no objetivos declarados por NUFORC.

Preguntas de análisis e hipótesis

El análisis busca responder tres preguntas. P1: ¿cómo varía el volumen de reportes según el año, el mes, el día de la semana y la hora? P2: ¿qué formas predominan y cómo se relacionan con la duración y la hora del avistamiento? P3: ¿es posible pronosticar el volumen mensual o semanal de reportes con un error útil para planear la operación? Además, se contrasta la hipótesis H1: el 4 de julio y el Año Nuevo (31 de diciembre y 1 de enero) concentran picos de reportes, con mayor proporción de las formas *fireball* y *light*, asociadas a fuegos artificiales y linternas.

Criterios de éxito

Los criterios de la Tabla 2 se fijaron antes de modelar, para evitar ajustar la meta al resultado. El umbral de MAPE se eligió por su interpretación operativa: con un error medio del 20 %, un pronóstico de 500 reportes implica que el valor real estará, en promedio, entre 400 y 600, margen suficiente para dimensionar un equipo. El contraste con el ingenuo estacional sigue la recomendación de Hyndman y Athanasopoulos (2021) de evaluar todo modelo frente a una referencia simple. Como no existe un requisito operativo real, los umbrales de la Tabla 2 también son supuestos del equipo.

Tabla 2

Criterios de éxito del proyecto

Código	Criterio	Umbral	Fase
CE1	MAPE del mejor modelo en el conjunto de prueba (2016)	≤ 20 % (ideal ≤ 15 %)	5
CE2	Reducción del MAE frente al ingenuo estacional	≥ 10 %	5
CE3	Residuos del modelo principal sin autocorrelación	Ljung-Box, $p > 0{,}05$	4
CE4	P1, P2 y H1 respondidas con evidencia estadística	Prueba y tamaño del efecto	2 y 6
CE5	Tablero que responda P1–P3 con interactividad	5 páginas; ≥ 5 tipos de visual	6

Nota. MAPE = error porcentual absoluto medio; MAE = error absoluto medio.

Plan del proyecto

La Tabla 3 resume las actividades, los entregables y las herramientas de cada fase de CRISP-DM. Todo el procesamiento se realizó en un cuaderno de Jupyter reproducible y el despliegue, en Power BI.

Tabla 3

Plan del proyecto organizado por las fases de CRISP-DM

Fase	Actividades principales	Entregable	Herramienta
1. Comprensión del negocio	Objetivos, preguntas, criterios de éxito	Sección 1 del cuaderno y del informe	Markdown
2. Comprensión de los datos	Documentación de la fuente, calidad, EDA univariado y bivariado	Figuras 1–9; tablas de calidad	pandas, SciPy, seaborn
3. Preparación (ETL)	Limpieza, imputación, ingeniería de variables, registro de cambios	Datos procesados en CSV; diccionario de datos	pandas, reverse_geocoder
4. Modelado	ADF, ACF/PACF, ingenuo estacional, SARIMA/Holt-Winters, Random Forest	Modelos ajustados y diagnóstico de residuos	statsmodels, scikit-learn
5. Evaluación	MAE, RMSE, MAPE; contraste con CE1–CE3; limitaciones	Tabla de métricas	pandas
6. Despliegue	Modelo en estrella, medidas DAX, tablero de cinco páginas	Archivo .pbix, informe y sustentación	Power BI

Nota. EDA = análisis exploratorio de datos; ETL = extracción, transformación y carga.

Fase 2: Comprensión de los datos

Fuente y documentación

Los datos provienen del National UFO Reporting Center (NUFORC, s. f.), organización sin ánimo de lucro que recopila reportes ciudadanos de avistamientos desde 1974 y publica cada uno en su sitio web. Se trata de la base pública de reportes de UAP más utilizada; además, cada registro conserva el enlace a su reporte original, lo que permite auditarlo. La Tabla 4 documenta los metadatos del archivo analizado. El archivo analizado proviene de la compilación abierta ufo-dedup de UFOSINT (s. f.), que importa los reportes de NUFORC directamente.

Tabla 4

Metadatos de la fuente de datos

Metadato	Valor
Organización	National UFO Reporting Center (NUFORC)
Sitio web	https://nuforc.org
URL de descarga	Archivo suministrado para el curso y entregado junto con este informe (data/raw); compilación de origen: github.com/UFOSINT/ufo-dedup
Fecha de acceso	No aplica (archivo suministrado para el curso)
Archivo	uap-atlas-reports-2010-2100.csv (UTF-8, separador coma)
Periodo real	1 de enero de 2010 a 18 de enero de 2017
Unidad de observación	Un reporte ciudadano de avistamiento
Volumen	50.000 filas × 11 variables
Recolección	Reporte voluntario; forma y duración declaradas por quien reporta

Nota. El nombre del archivo indica el periodo 2010–2100, pero las fechas reales terminan el 18 de enero de 2017.

La Tabla 5 presenta el diccionario inicial de las once variables. Cuatro de ellas no aportan al análisis: *source* y *locationPrecision* son constantes (siempre «nuforc» y «city»), mientras que *id* y *sourceUrl* son identificadores únicos por fila.

Tabla 5

Diccionario inicial de variables

Variable	Tipo	Descripción	Únicos
id	Identificador	Identificador único del reporte	50.000
source	Categórica	Fuente del reporte (constante: nuforc)	1
datetime	Fecha/hora	Fecha y hora local (ISO 8601; a veces solo fecha)	40.191
lat	Continua	Latitud de la ciudad (grados decimales)	3.226
lng	Continua	Longitud de la ciudad (grados decimales)	5.570
shape	Categórica	Forma declarada del objeto	24
durationSec	Continua (razón)	Duración declarada, en segundos	174
country	Categórica	País (ISO 3166-1 alfa-3)	111
locationPrecision	Categórica	Precisión de la ubicación (constante: city)	1
status	Categórica	Estado de revisión del reporte	3
sourceUrl	Identificador	Enlace al reporte original	50.000

Nota. Elaboración propia a partir del archivo original.

Verificación inicial de la calidad

El diagnóstico de calidad, resumido en la Tabla 6, identificó diez problemas. Los más relevantes son tres. Primero, el año 2017 solo tiene 197 registros correspondientes a 18 días, por lo que se excluye de los análisis anuales y del modelo. Segundo, la variable *status* no puede usarse como variable objetivo de un modelo de clasificación: el 99,97 % de los reportes están «abiertos» (49.985), frente a 14 «explicados» y uno calificado como engaño, de modo que no existe variabilidad que aprender. Tercero, 1.624 registros (3,2 %) solo tienen fecha; si se convirtieran directamente a fecha y hora quedarían asignados a la medianoche y crearían un pico artificial a las 00:00, por lo que la hora de estos registros se trata como desconocida.

Tabla 6

Diagnóstico inicial de calidad y tratamiento previsto

Problema	**Magnitud**	**Tratamiento previsto (fase 3)**
Periodo del nombre del archivo incorrecto	Datos reales 2010–2017	Documentar; usar 2010–2016
Año 2017 incompleto	197 registros	Excluir de análisis anuales y del modelo
Variables constantes o identificadores	4 columnas	Eliminar del análisis (id se conserva como llave)
status casi constante	99,97 % open	Descartar como variable objetivo
Faltantes en durationSec	7.711 (15,4 %)	Mediana por forma y marca de faltante
Faltantes en country	1.443 (2,9 %)	Imputar desde latitud y longitud
Forma no informativa (nulo, unknown, other)	7.409 (14,8 %)	Unificar como «desconocida»
datetime sin hora	1.624 (3,2 %)	Marca hora_conocida
Duraciones extremas	Máximo 300.600 s; 11 casos > 24 h	Umbral de 24 h y escala logarítmica
Posibles duplicados (fecha, lat, lng, forma)	439 filas	Revisar en la fase 3

Nota. Latitud y longitud no tienen faltantes ni valores fuera de rango.

Los datos permiten responder las preguntas planteadas. La variable *datetime* está completa, lo que permite agregar por año, mes, día y hora (P1) y construir una serie mensual de 84 observaciones con seis ciclos anuales completos para entrenar y uno para evaluar (P3). La

forma y la duración están disponibles en cerca del 85 % de los registros (P2), y las coordenadas completas permiten el análisis geográfico y la recuperación del país faltante. La limitación principal no es el volumen sino la representatividad: los reportes son voluntarios y el 90 % proviene de Estados Unidos.

Análisis univariado

Duración del avistamiento

La Tabla 7 y la Figura 1 describen la duración declarada. En escala original, la media (542 s) triplica la mediana (180 s) y la asimetría (62,3) y la curtosis de exceso (5.050) son extremas, de modo que la media no representa al reporte típico y no debe utilizarse para imputar. En escala logarítmica de base 10 la distribución es aproximadamente simétrica (asimetría de −0,43) y el número de atípicos según la regla de Tukey pasa de 4.026 a 12, lo que justifica trabajar con *log_duracion*. Además, el 72,2 % de las duraciones son múltiplos de 60 s y los valores más frecuentes son 300, 120, 60 y 600 s: se trata de estimaciones redondeadas, por lo que la duración debe interpretarse como un orden de magnitud.

Tabla 7

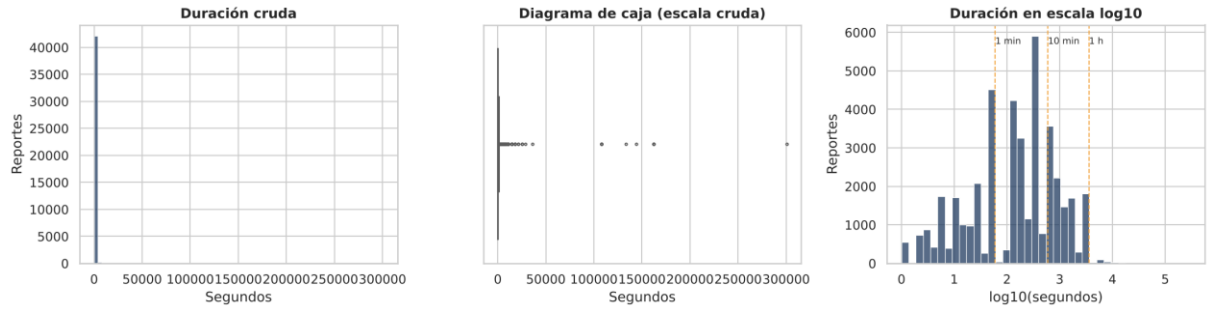
Medidas descriptivas de la duración declarada

Medida	Segundos	log10(segundos)
n	42.289	42.289
Media	542,0	2,11
Mediana	180,0	2,26
Moda	300,0	2,48
Desviación estándar	2.743,0	0,84
Q1 – Q3	40 – 600	1,60 – 2,78
Rango intercuartílico	560,0	1,18
Mínimo – máximo	1 – 300.600	0,00 – 5,48
Asimetría	62,29	−0,43
Curtosis de exceso	5.049,82	−0,37

Nota. Se excluyen los 7.711 registros sin duración.

Figura 1

Distribución de la duración declarada en escala original y logarítmica



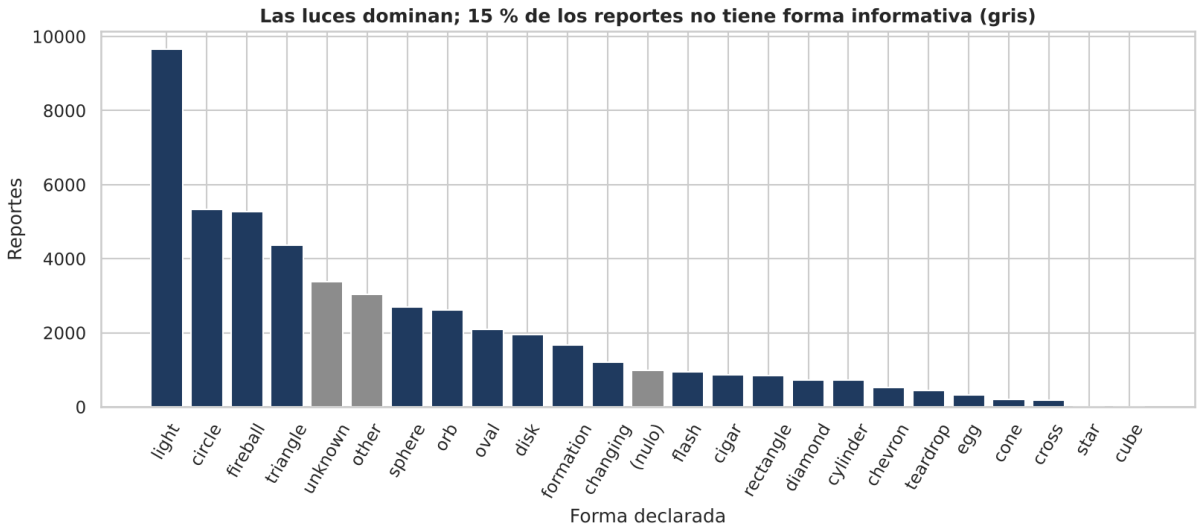
Nota. Las líneas punteadas del panel derecho marcan 1 minuto, 10 minutos y 1 hora.

Variables categóricas

La forma más frecuente es *light* (19,3 %), seguida de *circle* (10,7 %) y *fireball* (10,5 %); las cinco primeras formas suman más de la mitad de los reportes (Figura 2). En el extremo opuesto, *star* (7 casos) y *cube* (2 casos) son tan escasas que no permiten estimar ningún parámetro, lo que justifica agrupar las 24 categorías en seis grupos. En cuanto al país, Estados Unidos concentra el 90 % de los reportes, seguido de Canadá (3,4 %) y el Reino Unido (1,1 %); el índice de Herfindahl-Hirschman de 0,86 confirma una concentración extrema, por lo que los resultados describen esencialmente el proceso de reporte estadounidense.

Figura 2

Frecuencia de las formas declaradas



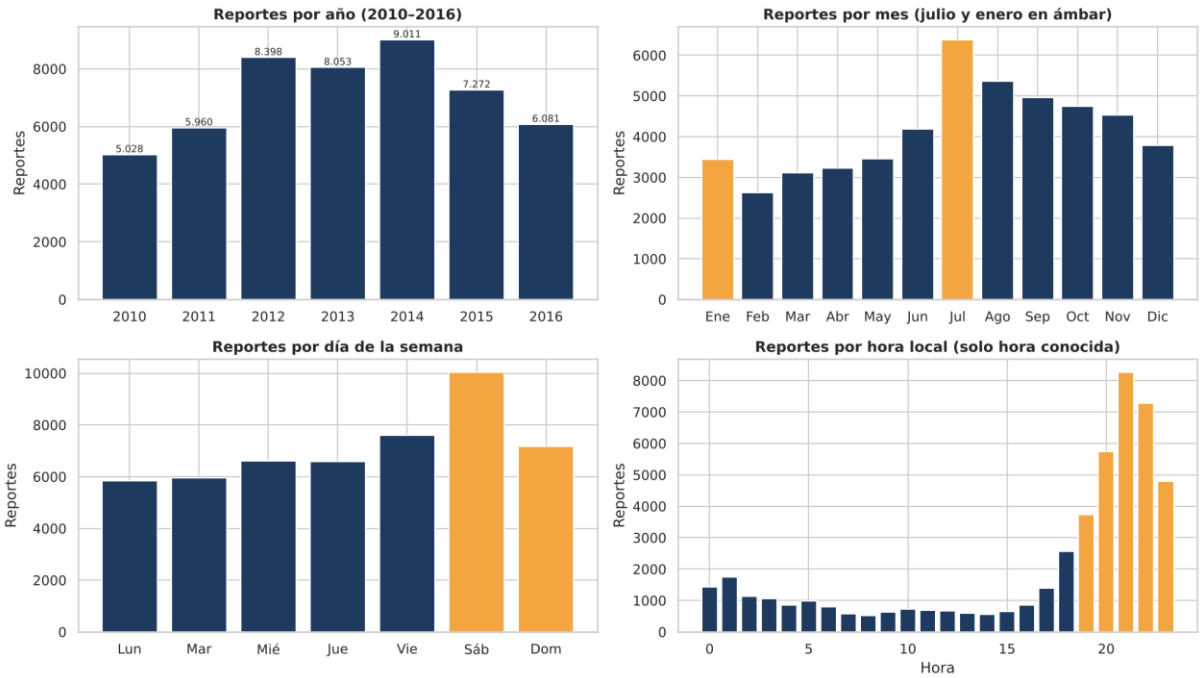
Nota. Las barras grises corresponden a categorías sin información sobre la forma (nulo, unknown y other).

Distribución temporal

La Figura 3 responde la primera pregunta de análisis. El volumen anual creció de 5.028 reportes en 2010 a 9.011 en 2014 y luego descendió hasta 6.081 en 2016, es decir, la tendencia no es monótona. Por mes, julio concentra el mayor volumen (6.383 reportes, 2,4 veces febrero). El sábado es el día con más reportes y el fin de semana reúne el 34,6 % del total, frente al 28,6 % que se esperaría si los siete días fueran equivalentes. Por hora, el 61,8 % de los reportes con hora conocida ocurre entre las 19:00 y las 23:00, con un máximo a las 21:00. Para el centro de recepción, esto indica que la carga es nocturna, estacional y mayor en verano, y para el modelado, que la serie tiene tendencia y estacionalidad anual.

Figura 3

Distribución de los reportes por año, mes, día de la semana y hora



Nota. Periodo 2010–2016. El panel de horas incluye solo los 48.185 reportes con hora conocida.

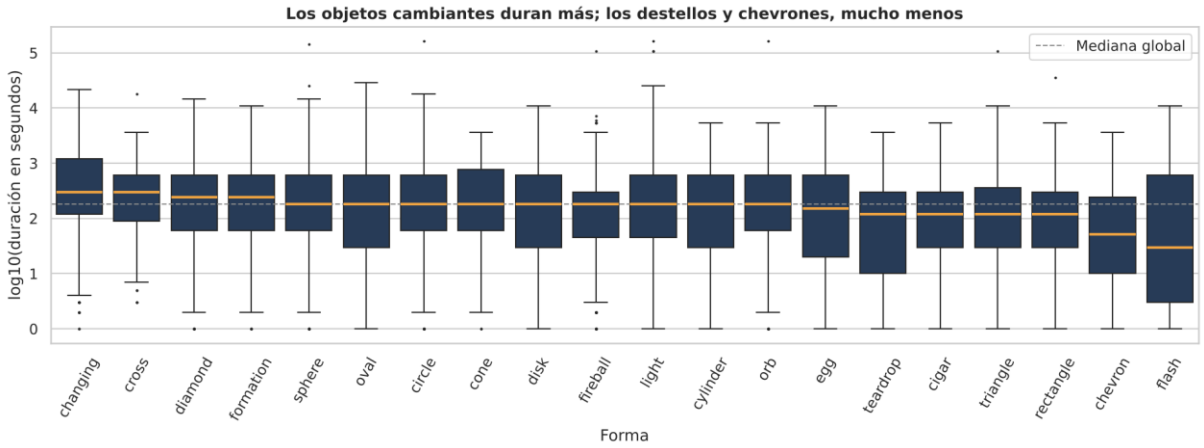
Análisis bivariado

Duración según la forma

Como la duración no sigue una distribución normal, se aplicó la prueba no paramétrica de Kruskal-Wallis (Kruskal y Wallis, 1952) a las 20 formas con al menos 30 casos. La prueba rechaza la igualdad de distribuciones ($H = 689{,}3$; $gl = 19$; $p < 0{,}001$), pero el tamaño del efecto es muy pequeño ($\eta^2_H = 0{,}018$; umbrales usuales de 0,01 pequeño, 0,06 mediano y 0,14 grande, según Tomczak y Tomczak, 2014). Con más de 36.000 observaciones cualquier diferencia resulta significativa, por lo que la interpretación se apoya en el tamaño del efecto. Los extremos son claros: *flash* (mediana de 30 s) y *chevron* (52,5 s) describen eventos breves, mientras que *changing* (300 s) se reporta como prolongado (Figura 4). Como las medianas extremas difieren hasta diez veces, los faltantes de duración se imputarán con la mediana de cada forma.

Figura 4

Duración declarada (log10) según la forma



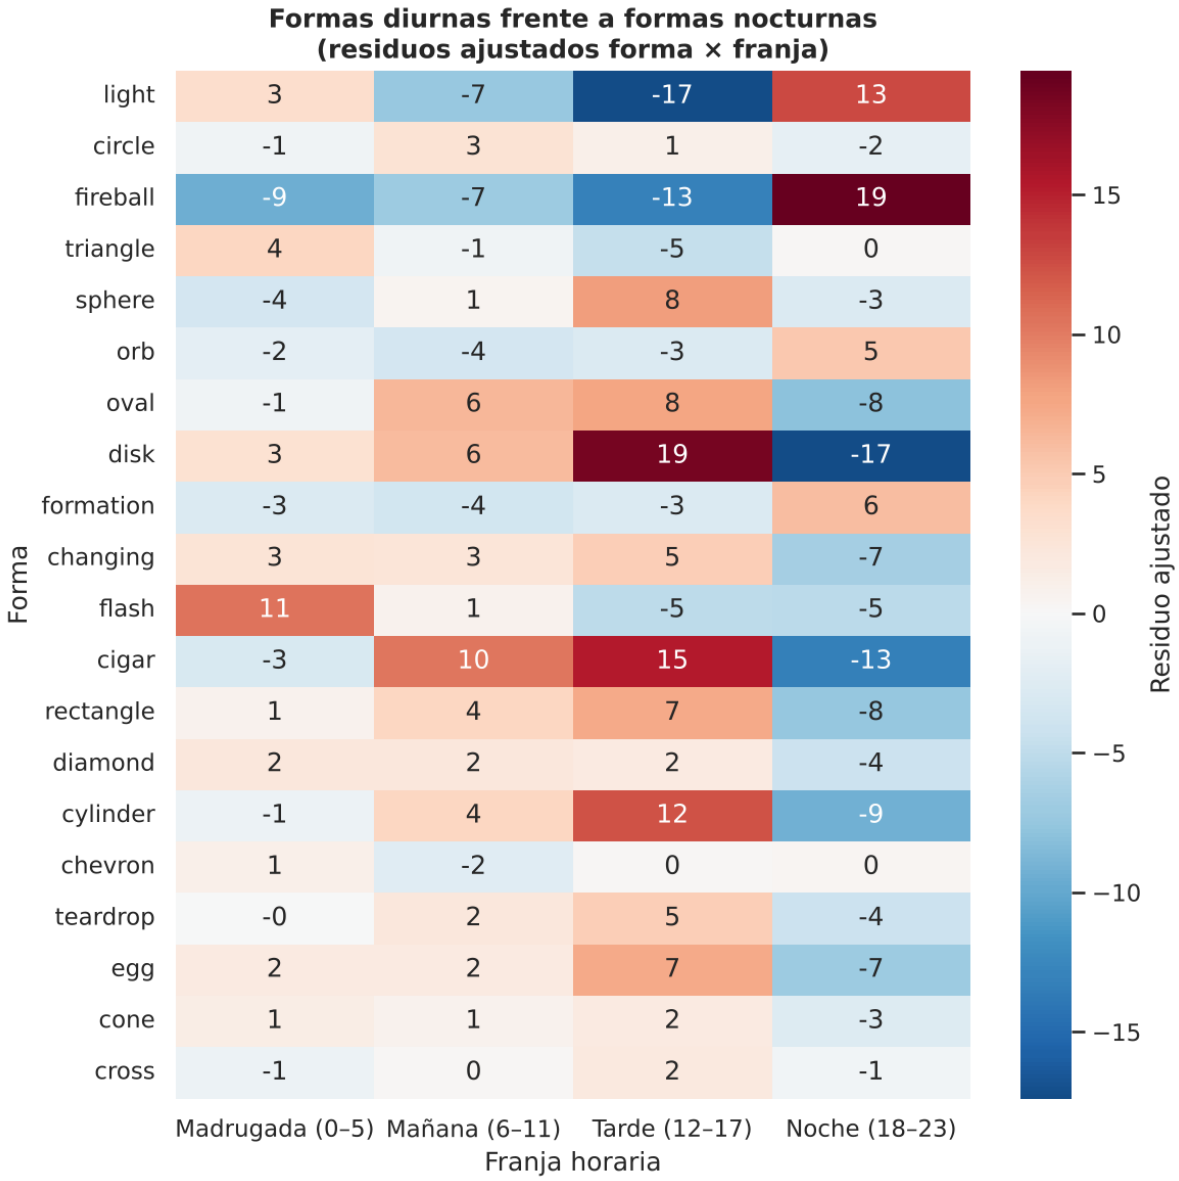
Nota. Formas ordenadas por mediana. Se excluyen los reportes sin forma informativa y las formas con menos de 30 casos.

Forma según la franja horaria

La tabla de contingencia entre forma y franja horaria muestra una asociación significativa pero débil ($\chi^2(57) = 2.287{,}5$; $p < 0{,}001$; V de Cramér = 0,136; Cramér, 1946), sin celdas con frecuencias esperadas menores que cinco. Los residuos estandarizados ajustados de la Figura 5 revelan un patrón coherente con las condiciones de observación: *fireball*, *light* y *formation* predominan de noche (el 80 % de los reportes de *fireball* ocurren entre las 18:00 y las 23:00), mientras que *disk*, *cigar* y *cylinder*, formas con contorno definido, predominan en la tarde, cuando es posible distinguir ese contorno. Para el negocio, esto implica que el turno nocturno recibirá sobre todo reportes de luces.

Figura 5

Residuos estandarizados ajustados de la tabla de contingencia forma × franja horaria



Nota. Valores absolutos mayores que 2 indican una asociación local significativa al 5 %. Rojo: más casos de los esperados; azul: menos.

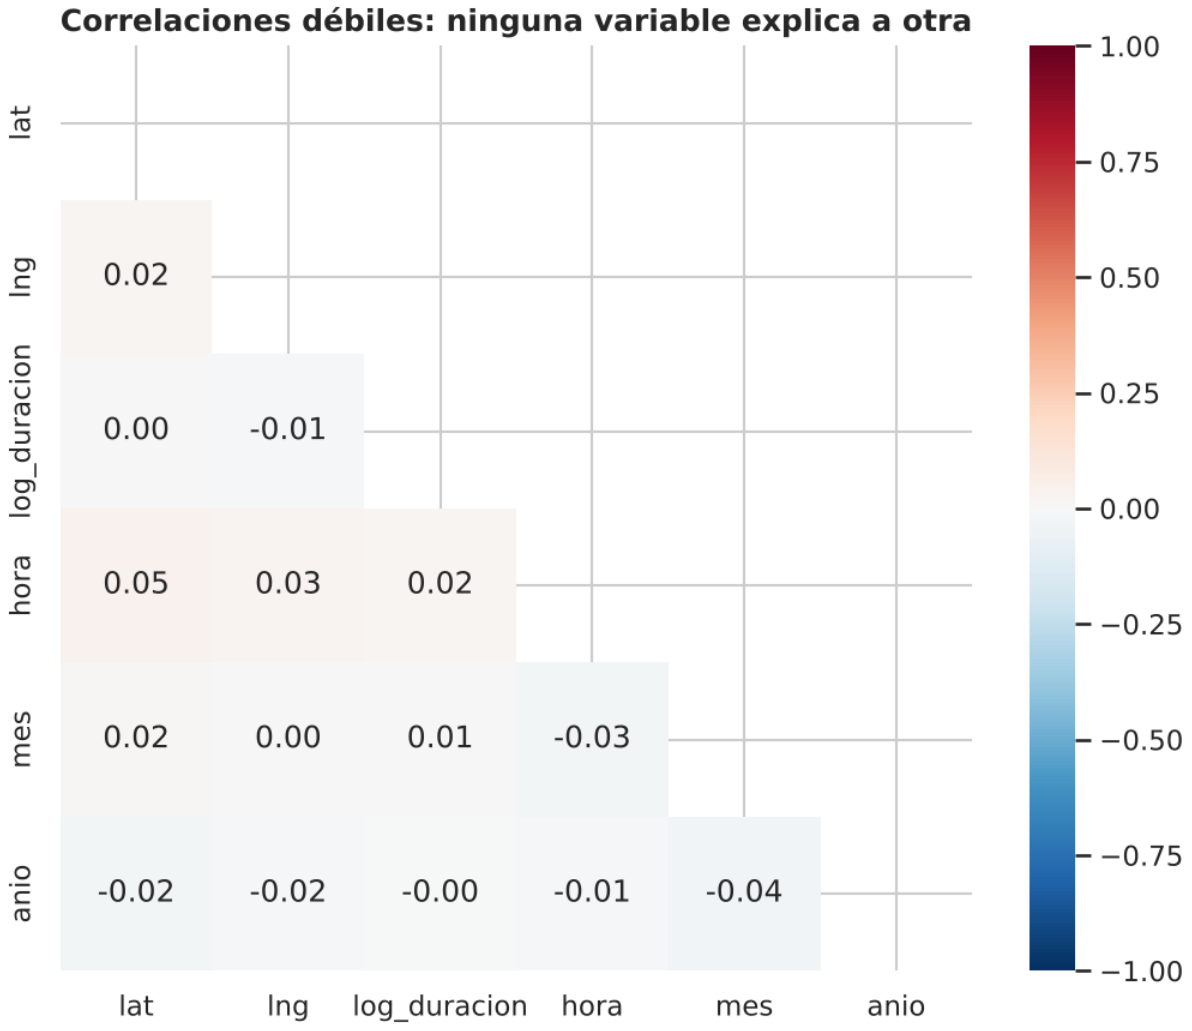
Correlaciones entre variables cuantitativas

La matriz de correlación de Spearman (Figura 6) muestra coeficientes prácticamente nulos entre latitud, longitud, duración logarítmica, hora, mes y año ($|\rho| \leq 0{,}046$). La duración no

se relaciona con las variables de calendario, de modo que no aporta a la predicción del volumen, y no existe multicolinealidad que impida usar varias variables de calendario en el Random Forest. Como la hora y el mes son variables cíclicas, cuya relación no capta un coeficiente de rangos, su efecto se analiza mediante el mapa de calor.

Figura 6

Matriz de correlación de Spearman



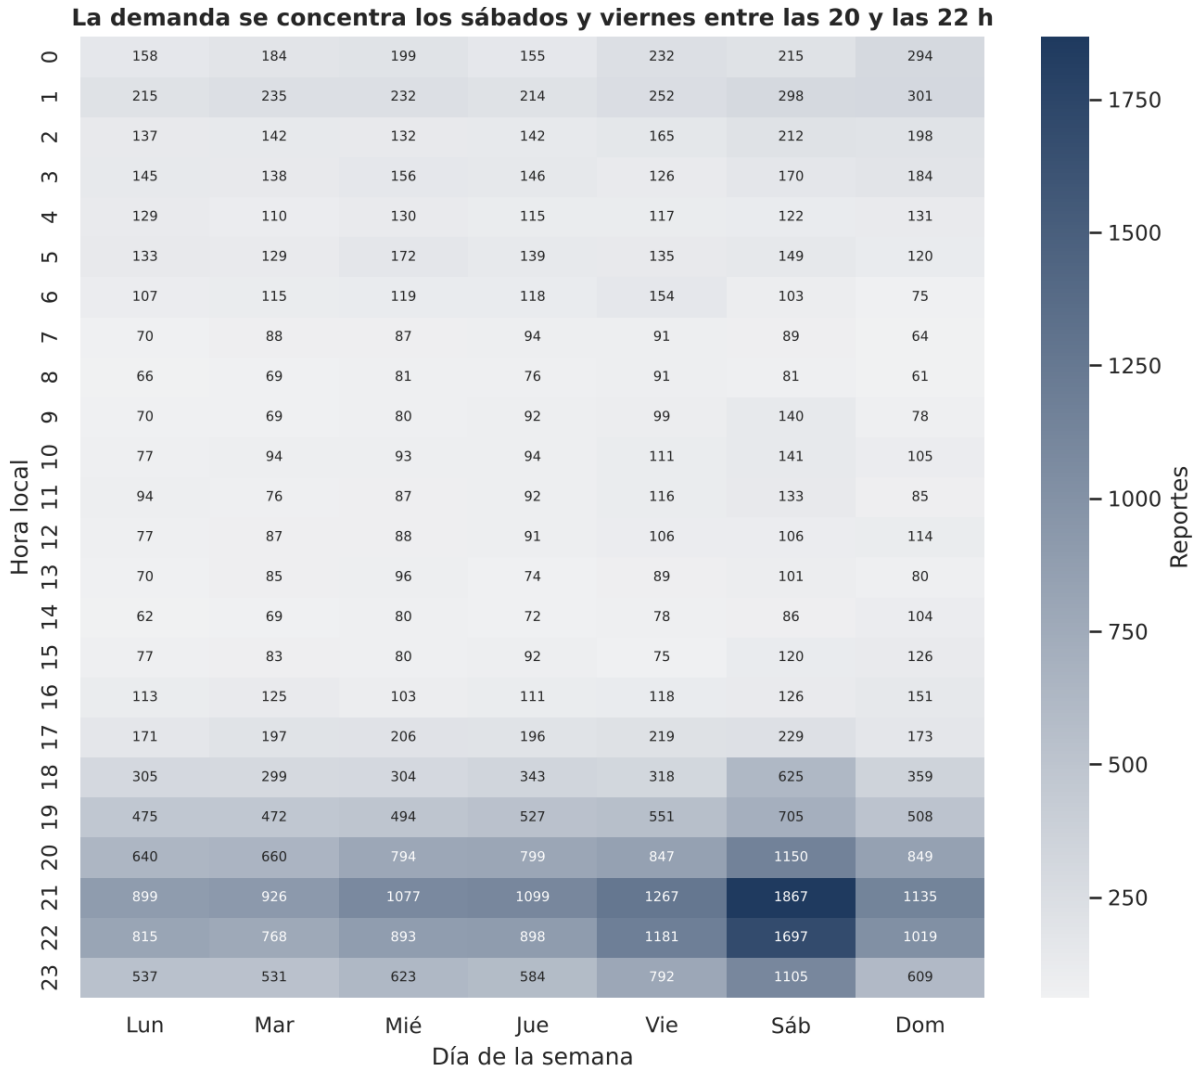
Nota. Periodo 2010–2016, con eliminación de faltantes por pares.

Hora y día de la semana

El mapa de calor de la Figura 7 muestra que la combinación de mayor demanda es el sábado a las 21:00 (1.867 reportes, 30,6 veces la celda mínima), seguida del sábado a las 22:00 y del viernes a las 21:00 y 22:00. La interacción entre hora y día es consistente con un efecto de exposición: los fines de semana por la noche hay más personas al aire libre que pueden observar el cielo. Esta matriz funciona como un plan de turnos para el centro de recepción.

Figura 7

Reportes por hora local y día de la semana



Nota. Incluye solo reportes con hora conocida del periodo 2010–2016.

Serie diaria y festivos con pirotecnia

La Figura 8 permite contrastar la hipótesis H1. Siete de los diez días con más reportes son festivos con pirotecnia (los seis 4 de julio de 2010 a 2015 y el 1 de enero de 2014), y la mediana diaria en esos días es 4,5 veces la de un día común (77 frente a 17 reportes; prueba de Mann-Whitney unilateral, $p < 0{,}001$). El efecto del 4 de julio es mucho mayor que el de Año Nuevo. La proporción conjunta de *fireball* y *light* aumenta de 34,8 % a 39,8 % ($\chi^2 = 20{,}0$; $p < 0{,}001$; razón de momios = 1,24), pero el aumento se debe solo a *fireball*, que pasa de 12,0 % a 20,1 %, mientras que *light* disminuye de 22,8 % a 19,7 %. Por tanto, H1 se confirma parcialmente. Cabe precisar que la razón de 4,5 compara los festivos con todos los demás días del año y que julio y enero ya son meses de volumen alto. Como control, al comparar cada festivo con los demás días del mismo mes, la razón de medianas es 4,6 en enero, 9,0 en julio y 3,1 en diciembre: el efecto no es un artefacto de la estacionalidad. Aun así, se basa en solo 21 días (siete años por tres fechas), por lo que debe leerse como una medida indicativa.

Los dos picos más notorios fuera de los festivos corresponden a eventos visibles de origen conocido. El máximo de toda la serie, el 7 de noviembre de 2015 (294 reportes), coincide con la prueba de un misil Trident II D5 lanzado desde un submarino frente al sur de California, confirmada por la Armada de Estados Unidos (Hinckley, 2015). El 27 de julio de 2016 (108 reportes) coincide con la reentrada de la etapa superior de un cohete chino Long March 7 sobre el oeste de Estados Unidos (Wall, 2016). Estos casos muestran que una parte de la demanda responde a eventos imprevisibles con el calendario, lo que constituye una limitación para el pronóstico.

Figura 8

Reportes diarios 2010–2016 con los festivos de pirotecnia resaltados



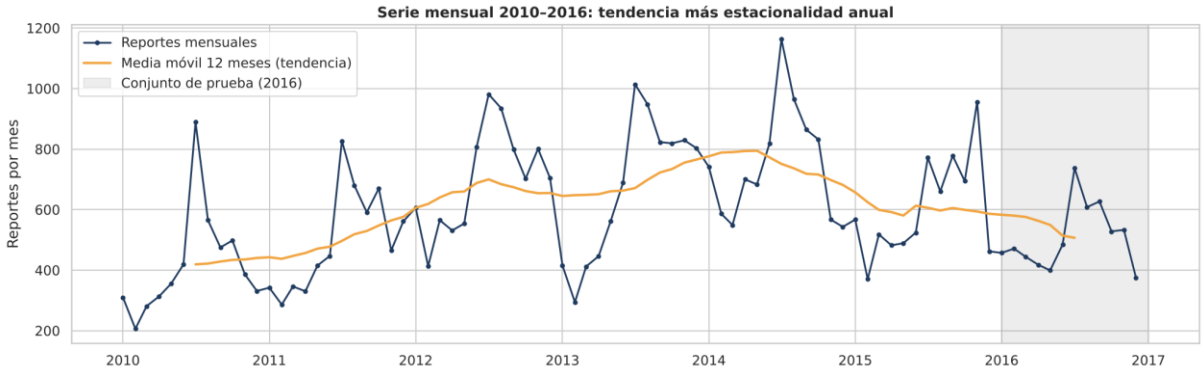
Nota. Puntos ámbar: 4 de julio, 31 de diciembre y 1 de enero. Las etiquetas rojas señalan los dos mayores picos en días no festivos.

Serie mensual

La serie mensual (Figura 9) combina una tendencia creciente hasta 2014 y decreciente después (la media mensual pasa de 419 reportes en 2010 a 751 en 2014 y a 507 en 2016) con un patrón anual que se repite, confirmado por una autocorrelación de 0,63 en el rezago 12. Estas características orientan la fase de modelado hacia métodos que representen tendencia y estacionalidad (Hyndman y Athanasopoulos, 2021). Dado que 2016 prolonga la caída iniciada en 2015, un modelo con pendiente fija tendería a sobreestimar el conjunto de prueba, por lo que se evitará extrapolar una pendiente fija y se compararán configuraciones con tendencia amortiguada, con diferenciación o sin tendencia.

Figura 9

Serie mensual de reportes, 2010–2016



Nota. La franja gris corresponde al conjunto de prueba (2016). La línea ámbar es la media móvil centrada de 12 meses.

Síntesis: de los hallazgos a las decisiones

La Tabla 8 resume cómo cada hallazgo del análisis exploratorio orienta las decisiones de preparación de los datos y de modelado.

Tabla 8

Hallazgos del análisis exploratorio y decisiones derivadas

Hallazgo	Decisión en la preparación	Decisión en el modelado
Duración asimétrica, redondeada y con extremos	Umbral de 24 h; log_duracion; rango_duracion	La duración no entra al modelo de volumen
Duración distinta según la forma (efecto pequeño)	Imputación con mediana por forma y marca de faltante	—
24 formas, algunas muy raras; 15 % sin forma	grupo_forma (6 grupos) y categoría «desconocida»	—
Forma asociada a la franja horaria	Variable franja_dia	Segmentación en el tablero
1.624 registros sin hora	Marca hora_conocida	Sin efecto en conteos diarios o mensuales
Picos el 4 de julio, con más fireball	Variable festivo_pirotecnia	Variable de calendario en Random Forest
Tendencia no monótona y estacionalidad anual	Agregación mensual y semanal	SARIMA y Holt-Winters (configuración elegida por AICc) frente al ingenuo estacional
Picos por eventos no festivos	Se conservan (son reportes reales)	Limitación del pronóstico
2017 incompleto	Excluir	Serie 2010–2016
90 % de reportes de Estados Unidos	Imputar país desde coordenadas	Limitación de generalización

Fase 3: Preparación de los datos

La preparación siguió un proceso de extracción, transformación y carga (ETL) completamente programado en el cuaderno de trabajo. El archivo original se almacenó en la carpeta data/raw, que no se modifica en ningún punto del cuaderno y todas las transformaciones se aplicaron sobre una copia, de modo que cualquier persona puede regenerar el dataset procesado ejecutando el cuaderno de principio a fin. Cada etapa quedó registrada mediante una función de bitácora que guarda las dimensiones de la tabla antes y después del cambio y el número de registros afectados (Tabla 9). Se usaron las bibliotecas pandas (McKinney, 2010), scikit-learn (Pedregosa et al., 2011) y statsmodels (Seabold y Perktold, 2010).

Tabla 9

Registro de cambios del proceso ETL

Paso	Etapa	Filas	Columnas	Afectados
1	Extracción del archivo original	0 → 50.000	0 → 11	50.000
2	Conversión de fecha y marca hora_conocida	50.000	11 → 12	1.624
3	Marca de posibles duplicados (se conservan)	50.000	12 → 13	439
4	Unificación de forma desconocida y grupo_forma	50.000	13 → 15	7.409
5	Imputación del país desde coordenadas	50.000	15 → 16	1.443
6	Duraciones mayores de 24 h como no válidas	50.000	16 → 17	11
7	Imputación de la duración con mediana por forma	50.000	17 → 19	7.722
8	Eliminación de columnas sin valor analítico	50.000	19 → 15	0
9	Exclusión de 2017 (año incompleto)	50.000 → 49.803	15	197
10	Ingeniería de variables	49.803	15 → 27	49.803
11	Exportación a CSV	49.803	27	49.803
12	Segmentación geográfica (K-means)	49.803	27 → 28	49.803

Nota. Elaboración propia a partir del registro generado por la función log_step del cuaderno, exportado como registro_etl.csv.

Tratamientos de limpieza

Fechas. La variable datetime se convirtió a tipo fecha y hora con el estándar ISO 8601. Los 1.624 registros que solo tenían la fecha se marcaron con la variable hora_conocida, en lugar de eliminarse: su fecha es válida para los conteos diarios, semanales y mensuales, pero se excluyen del análisis por hora para no generar un pico artificial a medianoche.

Duplicados. Se identificaron 439 registros que repiten fecha, hora, coordenadas y forma con otro reporte. Antes de decidir, se examinó su naturaleza. Dentro de cada grupo, los números de reporte asignados por NUFORC están separados una mediana de nueve posiciones y solo el 21,6 % son consecutivos, lo que indica envíos independientes y no reenvíos de la misma persona. Además, se concentran en eventos masivos, como el 4 de julio y el 7 de noviembre de 2015. Como la unidad de observación es el reporte y cada uno representa carga de trabajo para el centro, se conservaron con la marca posible_duplicado; eliminarlos habría modificado la serie mensual hasta en un 1,9 % y subestimado la demanda precisamente en los días pico.

Forma. Los valores nulos y las categorías *unknown* y *other* se unificaron en la categoría «desconocida» (7.409 registros), porque para el negocio expresan lo mismo: la persona no pudo describir la forma. Se conservó la forma original en la variable forma_reportada para garantizar la trazabilidad.

País. Como las coordenadas no tienen faltantes, el país de los 1.443 registros sin dato se dedujo de ellas. El método principal fue la geocodificación inversa sin conexión (reverse_geocoder) y el de respaldo, el vecino más cercano según la distancia de Haversine entre reportes con país conocido. Este último alcanzó una exactitud del 99,8 % al predecir el país de una muestra de validación del 20 % de los registros con país conocido. Imputar con la moda habría asignado Estados Unidos a reportes de Europa, Asia y Oceanía.

Duración. Se fijó un umbral de 24 horas con criterio de negocio: una observación continua de más de un día no es plausible como avistamiento único. El umbral, además, se ubica a 3,35 desviaciones estándar de la media en escala logarítmica. Los 11 valores que lo superan se trataron como no válidos en lugar de recortarse, para no inventar una duración. Los 7.722 valores faltantes resultantes se imputaron con la mediana de la forma correspondiente, o con la del grupo de formas cuando la forma tenía menos de 30 duraciones válidas, porque la media triplica la mediana y la duración difiere entre formas (Fase 2). La imputación mantiene la mediana global (180 s) pero reduce el rango intercuartílico de 562 s a 240 s; por esa razón, el tablero y las estadísticas descriptivas usan la duración reportada sin imputar.

Columnas y periodo. Se eliminaron source y locationPrecision, por ser constantes; status, por su falta de variabilidad; y sourceUrl, por ser redundante con el identificador. Se excluyeron los 197 registros de 2017, cuyo año está incompleto: incluirlos habría simulado una caída del 97 % en el volumen anual.

Ingeniería de variables

Se derivaron variables temporales (fecha, año, mes, día de la semana, hora, fin de semana y franja del día) para responder P1 y relacionar los datos con la tabla calendario del tablero. Se crearon tres variables justificadas por el análisis exploratorio. La primera es festivo_pirotecnia, porque esos días multiplican por 4,5 el volumen diario. La segunda es log_duracion, que reduce la asimetría de 62,3 a −0,43. La tercera es rango_duracion, que respeta el carácter aproximado de las estimaciones. Las 24 formas se agruparon en seis grupos con tamaños suficientes para la comparación (luces, redondas, angulares, alargadas, formación o cambiante y desconocida). Por último, se construyeron las agregaciones mensual (84 meses) y semanal (364 semanas

completas) requeridas por los modelos de series de tiempo. El esquema final, de 28 variables, se documenta en el Anexo A.

Carga

Los resultados se exportaron a la carpeta data/processed en formato CSV con codificación UTF-8, separador coma, punto decimal, fechas en formato ISO y variables booleanas como 0 y 1, de modo que Power BI los carga sin ajustes manuales. La Tabla 10 describe los archivos generados. El cuaderno verifica al final que cada archivo se pueda leer, que las llaves de las dimensiones sean únicas y que exista integridad referencial entre la tabla de hechos y sus dimensiones.

Tabla 10

Archivos generados por el proceso ETL

Archivo	Contenido	Filas
uap_procesado.csv	Tabla de hechos: un reporte por fila	49.803
dim_forma.csv	Dimensión de formas con nombre en español y grupo	23
dim_pais.csv	Dimensión de países con nombre, región y centroide	111
fact_pronostico.csv	Valores reales, pronósticos e intervalos por modelo	598
metricas_modelo.csv	MAE, RMSE, MAPE y cumplimiento de criterios por modelo	7
serie_mensual.csv / serie_semanal.csv	Series agregadas para el modelo	84 / 364
diccionario_datos.csv / registro_etl.csv	Documentación y trazabilidad	28 / 12

Fase 4: Modelado

Tipo de tarea y selección de modelos

La pregunta P3 exige anticipar un conteo de reportes en periodos futuros, por lo que la tarea corresponde a un pronóstico de series de tiempo. Se descartó la clasificación, porque la única variable candidata (status) no tiene variabilidad, y también la regresión transversal, porque las observaciones mensuales no son independientes. Además, el análisis exploratorio mostró que las demás variables se relacionan débilmente entre sí ($|\rho| \leq 0{,}05$; V de Cramér = 0,136; η^2_H =

0,018), de modo que los modelos más conocidos de clasificación o regresión no tendrían una variable objetivo que predecir con los datos disponibles; y, como no se conocen los objetivos reales de la organización, se eligió el único objetivo que los datos permiten definir y medir: la demanda de reportes en el tiempo. El análisis exploratorio mostró tres rasgos que orientaron la selección: estacionalidad anual, una tendencia que cambia de dirección en 2014 y picos por eventos puntuales. La Tabla 11 resume los modelos comparados.

Tabla 11

Modelos comparados y justificación

Rol	Modelo	Justificación
Referencia	Ingenuo estacional	Repite el mismo mes del año anterior; es la referencia mínima para series estacionales (Hyndman y Athanasopoulos, 2021)
Principal (candidato)	SARIMA(p,d,q)(P,D,Q)$_{12}$	Modela autocorrelación y estacionalidad mediante diferenciación; órdenes guiados por ADF, ACF y PACF
Principal (candidato)	Holt-Winters	Suavizado exponencial con nivel, tendencia (aditiva, amortiguada o ninguna) y estacionalidad; la configuración se elige por AICc
Alternativa	Random Forest	Modelo no paramétrico con variables de calendario y el rezago de 12 meses (Breiman, 2001)

Para evitar la fuga de información, la serie se dividió en entrenamiento (2010–2015, 72 meses) y prueba (2016, 12 meses); el conjunto de prueba se usó una sola vez. Los parámetros de cada familia se eligieron con el criterio de información de Akaike (AIC o AICc) en el entrenamiento. La elección entre SARIMA y Holt-Winters como modelo principal se hizo con una validación interna: se entrenó con 2010–2014 y se validó con 2015.

Ajuste de eventos puntuales

En el entrenamiento se reemplazaron por la mediana móvil de 31 días los días que superaron cinco veces esa mediana y no eran festivos con pirotecnia. La regla identificó dos días: el 22 de mayo de 2011 (69 reportes frente a una mediana de 10) y el 7 de noviembre de 2015 (294 frente a 23). En total se retiraron 330 reportes, el 0,75 % del entrenamiento (Figura 10). Sin

este ajuste, los modelos estacionales aprenderían un pico en noviembre que no se repite. Los festivos no se ajustaron, porque sí recurren cada año, y el conjunto de prueba se evaluó sin ajuste, contra la demanda real.

Figura 10

Partición entre entrenamiento y prueba y efecto del ajuste de eventos puntuales



Nota. La línea gris muestra la serie original en los meses ajustados (mayo de 2011 y noviembre de 2015).

Verificación de supuestos y parámetros

La descomposición aditiva de la serie de entrenamiento (Figura 11) muestra una fuerza de la estacionalidad de 0,87 y una fuerza de la tendencia de 0,79, en una escala de 0 a 1. La prueba aumentada de Dickey-Fuller (Dickey y Fuller, 1979) se aplicó a la serie original y a sus diferencias (Tabla 12). La serie original no es estacionaria ($p = 0{,}377$) y la diferencia estacional por sí sola no basta ($p = 0{,}073$), de modo que, según la regla definida antes de estimar, se fijó $D = 1$ y $d = 1$; con ambas diferencias la serie sí es estacionaria ($p < 0{,}001$). Como la prueba tiene poca potencia con 51 a 59 observaciones, los órdenes se validaron además con los residuos y los criterios de información. Los correlogramas de la serie diferenciada (Figura 12) muestran un rezago 1 negativo en la ACF, compatible con un término de medias móviles, y orientaron la búsqueda de órdenes $p, q \in \{0, 1, 2\}$ y $P, Q \in \{0, 1\}$.

Tabla 12

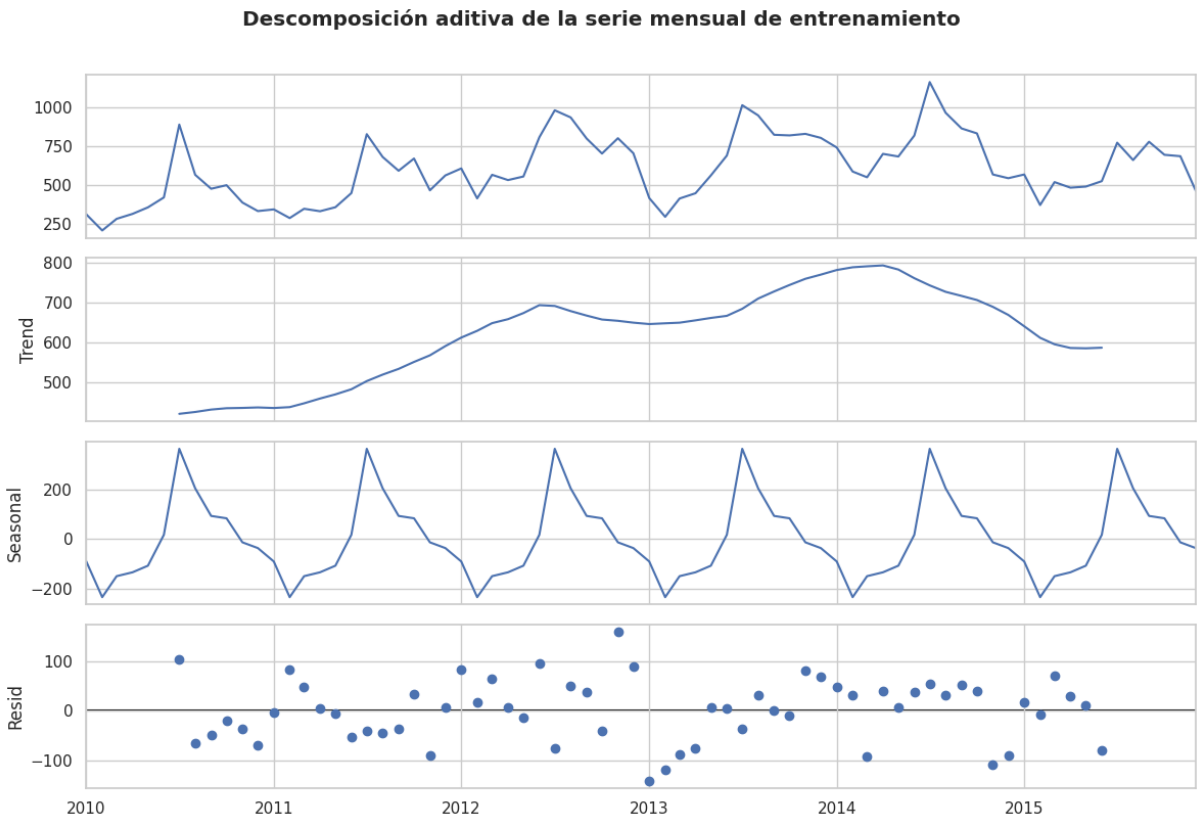
Prueba aumentada de Dickey-Fuller sobre la serie mensual de entrenamiento

Serie	Estadístico ADF	Valor p	Conclusión
Original	−1,81	0,377	No estacionaria
Primera diferencia (d = 1)	−1,86	0,349	No estacionaria
Diferencia estacional (D = 1)	−2,70	0,073	No estacionaria
d = 1 y D = 1	−4,80	< 0,001	Estacionaria

Nota. H_0: la serie tiene raíz unitaria (no es estacionaria). Se rechaza con $p < 0,05$.

Figura 11

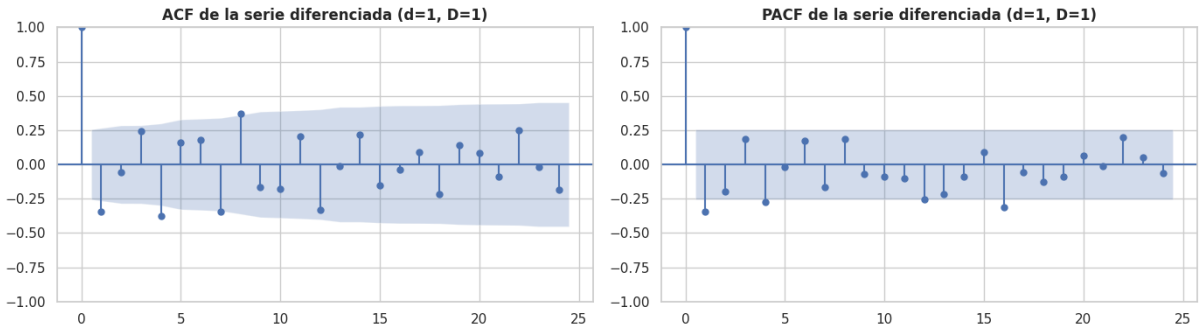
Descomposición aditiva de la serie mensual de entrenamiento



Nota. Periodo 2010–2015, con el ajuste de eventos puntuales.

Figura 12

Funciones de autocorrelación y autocorrelación parcial de la serie diferenciada



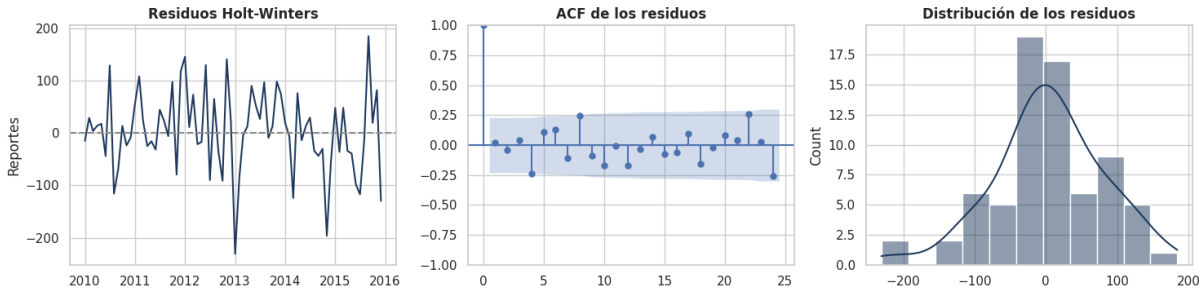
Nota. Las bandas sombreadas corresponden al intervalo de confianza del 95 %.

El modelo SARIMA seleccionado fue SARIMA$(0,1,1)\times(0,1,1)_{12}$ (AIC = 719,4), el de menor AIC entre los que superaron la prueba de Ljung-Box. Su coeficiente de media móvil estacional (−0,994) está en el límite de invertibilidad, señal de que la estacionalidad es casi determinista y de una posible sobrediferenciación. La mejor configuración de Holt-Winters por AICc (663,9) fue sin tendencia y con estacionalidad aditiva, con parámetros de suavizado α = 0,555 y γ = 0,0 (factor estacional fijo); β y φ no aplican porque el modelo no tiene tendencia. En la validación con 2015, Holt-Winters obtuvo el menor MAPE (12,55 % frente a 13,17 % de SARIMA y 33,22 % del ingenuo), por lo que se designó como modelo principal. El Random Forest usó 500 árboles, un mínimo de dos observaciones por hoja y una semilla fija; las variables más importantes fueron el mes (0,43), el rezago de 12 meses (0,32) y el índice temporal (0,23).

El diagnóstico de los residuos del modelo principal (Figura 13) con la prueba de Ljung-Box (Ljung y Box, 1978) arrojó un valor *p* de 0,097 en el rezago 12, por lo que no se rechaza la hipótesis de ausencia de autocorrelación, aunque con poco margen; en el rezago 24, en cambio, *p* = 0,028, es decir, queda autocorrelación de largo plazo. Los residuos son compatibles con una distribución normal (Shapiro-Wilk, *p* = 0,420).

Figura 13

Diagnóstico de los residuos del modelo principal



Nota. De izquierda a derecha: residuos en el tiempo, función de autocorrelación y distribución.

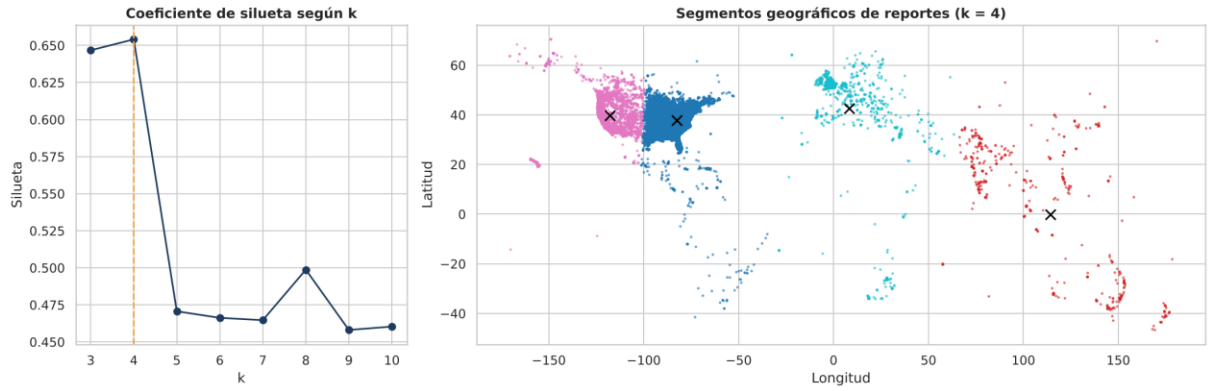
Variante semanal y segmentación geográfica

Como variante, se modeló la serie semanal (período 52) con el ingenuo estacional, Holt-Winters y un Random Forest que incluye una marca de semana con festivo. Se omitió SARIMA porque un período estacional de 52 es costoso de estimar e inestable con seis años de datos (Hyndman y Athanasopoulos, 2021). La última semana de entrenamiento (28 de diciembre de 2015 a 3 de enero de 2016) incluye tres días de 2016; el efecto es marginal, pero se declara como limitación.

De forma complementaria, se aplicó K-means sobre la latitud y la longitud para identificar zonas de concentración. El número de grupos se eligió entre 3 y 10 con el coeficiente de silueta (Rousseeuw, 1987), calculado sobre una muestra fija de 10.000 puntos. La solución de cuatro grupos obtuvo la mayor silueta (0,654), apenas superior a la de tres (0,647). Los segmentos resultantes son el este y el centro de Estados Unidos, junto con el este de Canadá y Latinoamérica (65,4 %); el oeste de Estados Unidos, con Alaska y Hawái (31,0 %); Europa y África (2,5 %); y Asia y Oceanía (1,2 %) (Figura 14). Para el centro de recepción, esto sugiere dos equipos regionales en Estados Unidos, en una proporción cercana a dos a uno, que además operan en husos horarios distintos.

Figura 14

Coeficiente de silueta y segmentos geográficos obtenidos con K-means



Nota. Las cruces indican los centroides. La distancia euclidiana en grados se distorsiona lejos del ecuador.

Fase 5: Evaluación

Desempeño en el conjunto de prueba

La Tabla 13 compara los modelos en 2016 con tres métricas complementarias: el error absoluto medio (MAE), expresado en reportes; la raíz del error cuadrático medio (RMSE), que penaliza los errores grandes; y el error porcentual absoluto medio (MAPE), que permite contrastar con el criterio CE1. El ingenuo estacional obtuvo un MAPE de 19,1 %: copiar 2015 sobreestima 2016, porque la caída del volumen continuó. El Random Forest tuvo el MAPE mensual más alto (21,2 %, un 3,3 % peor que la referencia en MAE), lo que es coherente con su incapacidad para extrapolar niveles fuera del rango de entrenamiento. Holt-Winters, el modelo principal, obtuvo un MAE de 87,3 reportes y un MAPE de 17,2 %, una reducción de 6,6 % del MAE frente a la referencia. SARIMA, pese a su mejor AIC y a sus residuos sin autocorrelación, quedó por debajo de la referencia (MAE de 100,6; MAPE de 19,9 %; −7,6 %), porque un buen ajuste dentro de la muestra no garantiza un buen pronóstico. En la variante semanal, Holt-

Winters también obtuvo el mejor MAPE (23,4 %), mientras que el Random Forest logró el menor RMSE (34,1). La Figura 15 compara los valores reales con los pronosticados.

Tabla 13

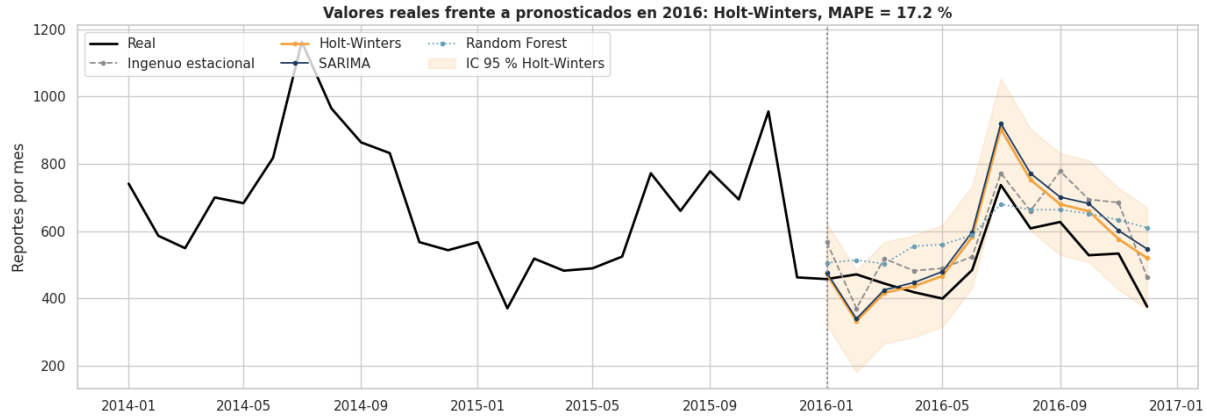
Métricas de desempeño en el conjunto de prueba (2016)

Serie	Modelo	MAE	RMSE	MAPE	Mejora MAE
Mensual	Ingenuo estacional	93,5	102,7	19,1 %	—
Mensual	SARIMA	100,6	116,1	19,9 %	−7,6 %
Mensual	Holt-Winters	87,3	102,6	17,2 %	6,6 %
Mensual	Random Forest	96,6	112,2	21,2 %	−3,3 %
Semanal	Ingenuo estacional	29,2	41,7	25,1 %	—
Semanal	Holt-Winters	26,4	41,4	23,4 %	9,4 %
Semanal	Random Forest	27,4	34,1	25,6 %	6,2 %

Nota. MAE y RMSE en reportes por periodo. La mejora del MAE se calcula frente al ingenuo estacional de la misma granularidad.

Figura 15

Valores reales y pronosticados de la serie mensual en 2016



Nota. La banda sombreada corresponde al intervalo de predicción aproximado del 95 % del modelo principal (±1,96 desviaciones estándar de los residuos de Holt-Winters).

Contraste con los criterios de éxito

Tabla 14

Cumplimiento de los criterios de éxito definidos en la Fase 1

Criterio	Umbral	Resultado	Veredicto
CE1. MAPE del modelo principal	≤ 20 % (ideal ≤ 15 %)	17,2 %	Se cumple (no alcanza el ideal de 15 %)
CE2. Mejora del MAE frente al ingenuo	≥ 10 %	6,6 %	No se cumple
CE3. Residuos sin autocorrelación	Ljung-Box p > 0,05	p = 0,097 (rezago 12); p = 0,028 (rezago 24)	Se cumple en el rezago 12
CE4. P1, P2 y H1 con evidencia estadística	Prueba y tamaño del efecto	Fase 2	Se cumple
CE5. Tablero que responde P1–P3	5 páginas, ≥ 5 tipos de visual	Fase 6	Se cumple

En términos operativos, el modelo principal se equivoca en promedio en 87 reportes por mes (MAE). Sobre un volumen cercano a 500 reportes mensuales (la media de 2016 fue 507), el margen es de ±87 reportes (±17 %) al planear cada mes. Según la Figura 15, los mayores errores, superiores a 100 reportes, se concentraron en febrero, cuando el modelo subestimó la demanda, y en julio, agosto, octubre y diciembre, cuando la sobreestimó: la caída del volumen iniciada en 2015 continuó en 2016 y el patrón estacional aprendido resultó más alto. En la variante semanal, el error es mayor, como se esperaba: al agregar por mes los errores semanales se compensan, y el 4 de julio cae en semanas diferentes cada año.

Limitaciones

Los resultados deben interpretarse con siete limitaciones. Primera, no se tuvo acceso a los objetivos reales de NUFORC ni de otra organización: los objetivos de negocio y los umbrales de éxito son supuestos del equipo y podrían cambiar con requisitos reales. Segunda, los reportes son voluntarios, de modo que la serie mide la propensión a reportar y no la frecuencia de los fenómenos; cambios en la visibilidad de NUFORC o en la cobertura mediática alteran el nivel

sin que cambie lo observado. Tercera, la serie es corta: seis ciclos estacionales para entrenar y uno para evaluar, por lo que el MAPE de prueba tiene una varianza alta y la mejora de 6,6 % frente a la referencia no es concluyente. Cuarta, el cambio de tendencia posterior a 2014 no tiene una variable explicativa en los datos. Quinta, el 90 % de los reportes proviene de Estados Unidos, lo que impide generalizar el modelo a otros países. Sexta, los festivos se repiten con intensidad variable y los eventos como pruebas de misiles o reentradas de cohetes son imprevisibles con el calendario. Séptima, la variante semanal tiene una semana de traslape con 2016 en el entrenamiento, con un efecto marginal.

Decisión sobre el uso del modelo

El modelo Holt-Winters aditivo sin tendencia cumple el criterio de error (CE1) pero no el de mejora frente a la referencia (CE2: 6,6 % frente al 10 % exigido), principalmente porque la serie es corta y 2016 es un único año de prueba en el que el ingenuo estacional ya era competitivo (MAPE de 19,1 %). Por tanto, sirve como referencia para la planeación mensual de capacidad con un margen de error cercano a ±17 %, combinado con reglas de calendario (refuerzo de los turnos del 4 de julio de forma independiente al pronóstico), pero no puede afirmarse que supere de forma clara a la práctica ingenua. Se recomienda reentrenarlo cada año, ampliar la serie e incorporar regresores externos. Como contraste informal, el pronóstico de enero de 2017 prorrateado a los 18 días observados (≈ 208 reportes) quedó solo ≈ 5 % por encima de los 197 reportes registrados, aunque esta verificación es orientativa.

Fase 6: Despliegue

Los resultados se desplegaron en un tablero de Power BI construido sobre un modelo en estrella. El modelo tiene dos tablas de hechos (reportes y pronósticos) y tres dimensiones (calendario, forma y país), con relaciones de uno a varios y filtro en una sola dirección (Tabla

15). La tabla calendario se creó en DAX con la función CALENDAR, entre 2010 y 2017, para incluir el pronóstico de 2017, y se marcó como tabla de fechas. En Power Query se fijó la referencia cultural en-US para interpretar correctamente el punto decimal, se parametrizó la ruta de los archivos y se documentaron los ajustes adicionales: duración en minutos, orden de las franjas, etiquetas legibles para los segmentadores y conversión de porcentajes.

Tabla 15

Relaciones del modelo de datos en Power BI

Tabla de dimensión (1)	Tabla de hechos (*)	Llave	Cardinalidad
dim_calendario	fact_reportes	Fecha → fecha	Uno a varios
dim_forma	fact_reportes	forma	Uno a varios
dim_pais	fact_reportes	pais	Uno a varios
dim_calendario	fact_pronostico	Fecha → fecha	Uno a varios

Nota. La tabla metricas_modelo no se relaciona con las demás porque contiene resultados agregados.

Se programaron 22 medidas DAX. Entre ellas están el total de reportes, la mediana de duración en minutos, el porcentaje de reportes nocturnos, la variación interanual, los reportes y el multiplicador de los festivos con pirotecnia, y, para el modelo, el MAE, el MAPE y la mejora frente al ingenuo. Estas últimas se calculan en DAX a partir de los pronósticos y reproducen las métricas obtenidas en Python, lo que sirve como control de consistencia. La Tabla 16 describe las cinco páginas del tablero y la pregunta a la que responde cada una.

Tabla 16

Páginas del tablero, visualizaciones y decisiones que apoyan

Página	Visualizaciones principales	Pregunta	Decisión
1. Resumen	Tarjetas KPI, líneas, barras	General	Visión de conjunto
2. Patrones temporales	Líneas, columnas, matriz hora × día con formato condicional	P1	Diseño de turnos y refuerzo en festivos
3. Geografía	Mapa, barras por país, anillo por segmento	Complementaria	Equipos regionales

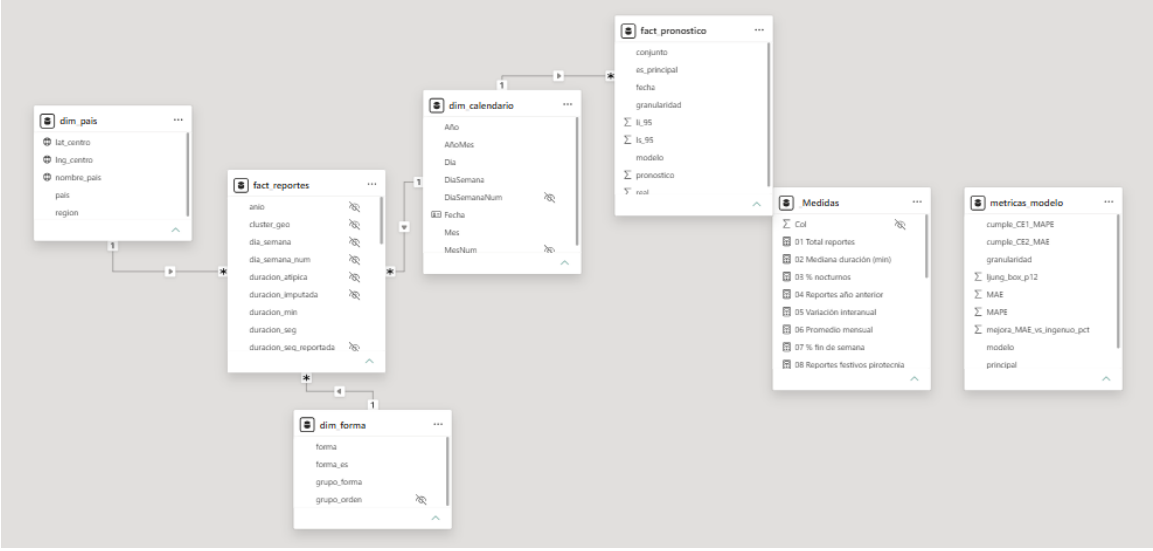
Página	Visualizaciones principales	Pregunta	Decisión
4. Formas y duración	Barras, histograma por rangos, treemap, barras 100 %	P2	Reglas de priorización
5. Modelo	Real frente a pronóstico, tabla de métricas, plan 2017	P3	Plantilla base mensual

Nota. Se usan más de diez tipos de visualización.

La interactividad incluye segmentadores sincronizados de año, región, país, grupo de forma y franja horaria; interacción cruzada entre visuales; una página de información sobre herramientas personalizada para las formas; una página de obtención de detalles por forma y por país; marcadores para la vista del 4 de julio, la vista fuera de Estados Unidos y el restablecimiento de filtros; y botones de navegación entre páginas. La paleta combina un fondo oscuro con verde y violeta como colores de énfasis, con tipografía Segoe UI y títulos que enuncian el hallazgo de cada página (Figuras 16 y 17).

Figura 16

Modelo en estrella implementado en Power BI



Nota. Captura de la vista de modelo de Power BI. Fuente: elaboración propia.

Figura 17

Página de resultados del modelo en el tablero de Power BI



Nota. Las capturas de las cinco páginas se incluyen en el Anexo C.

Conclusiones

En relación con la primera pregunta, el volumen de reportes presenta patrones temporales marcados y aprovechables para la planeación. El 61,8 % de los reportes con hora conocida ocurre entre las 19:00 y las 23:00, con un máximo el sábado a las 21:00. Julio concentra 2,4 veces el volumen de febrero, y el volumen anual creció hasta 2014 para luego descender. Los festivos con pirotecnia multiplican por 4,5 el volumen diario, sobre todo el 4 de julio, lo que confirma parcialmente la hipótesis H1: el aumento corresponde a la forma *fireball* y no a *light*.

En cuanto a la segunda pregunta, predominan las formas luminosas (*light*, 19,3 %), y la forma declarada se asocia de manera débil pero consistente con la franja horaria (V de Cramér = 0,136): las formas luminosas predominan de noche y las de contorno definido, de día. La duración difiere entre formas, con un efecto pequeño ($\eta^2_H = 0{,}018$) pero con extremos

operativamente relevantes, como los destellos de 30 segundos frente a los objetos cambiantes de cinco minutos.

Respecto de la tercera pregunta, es posible pronosticar el volumen mensual con el error definido como aceptable (MAPE ≤ 20 %), aunque la mejora sobre la referencia no alcanzó el umbral exigido. El modelo Holt-Winters aditivo sin tendencia alcanzó un MAPE de 17,2 % en 2016 y redujo el MAE en 6,6 % frente al ingenuo estacional (el umbral era 10 %); con un solo año de prueba, esa mejora no es concluyente. La serie semanal resultó más difícil de pronosticar (MAPE de 23,4 %), por la variabilidad de los festivos y la longitud del período estacional.

Estas conclusiones están condicionadas por el carácter voluntario de los reportes, la corta extensión de la serie, la concentración en Estados Unidos y la existencia de eventos imprevisibles, como la prueba de misil de noviembre de 2015, que produjo el mayor pico diario de la serie. Como trabajo futuro, se propone incorporar datos posteriores a 2016, regresores externos (calendarios de lanzamientos espaciales y lluvias de meteoros) y modelos jerárquicos por región. Todo el análisis parte de objetivos de negocio supuestos, porque no se tuvo acceso a los objetivos reales de la organización.

Referencias

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C. y Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS. https://s2.smu.edu/tfomby/eco5385_eco6380/data/SPSS/CRISPWP-0800%20Data%20Mining%20Standards.pdf

Cramér, H. (1946). *Mathematical methods of statistics*. Princeton University Press.

Dickey, D. A. y Fuller, W. A. (1979). Distribution of the estimators for autoregressive time series with a unit root. *Journal of the American Statistical Association, 74*(366a), 427–431. https://doi.org/10.1080/01621459.1979.10482531

Hinckley, S. (2015, 8 de noviembre). *What was up with that weird light in the sky?* The Christian Science Monitor. https://www.csmonitor.com/Science/2015/1108/What-was-up-with-that-weird-light-in-the-sky

Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Kruskal, W. H. y Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association, 47*(260), 583–621. https://doi.org/10.1080/01621459.1952.10483441

Ljung, G. M. y Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika, 65*(2), 297–303. https://doi.org/10.1093/biomet/65.2.297

McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61). https://doi.org/10.25080/Majora-92bf1922-00a

National Aeronautics and Space Administration. (2023). *Unidentified anomalous phenomena independent study team report*. https://science.nasa.gov/uap/

National UFO Reporting Center. (s. f.). *Base de datos de reportes de avistamientos* [Conjunto de datos]. https://nuforc.org

Office of the Director of National Intelligence. (2021). *Preliminary assessment: Unidentified aerial phenomena*. https://www.intelligence.gov/assets/documents/702%20Documents/declassified/Preliminary-Assessment-UAP-20210625.pdf

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M. y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Seabold, S. y Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 92–96). https://doi.org/10.25080/Majora-92bf1922-011

Tomczak, M. y Tomczak, E. (2014). The need to report effect size estimates revisited: An overview of some recommended measures of effect size. *Trends in Sport Sciences, 21*(1), 19–25. https://tss.awf.poznan.pl/The-need-to-report-effect-size-estimates-revisited-An-overview-of-some-recommended,188960,0,2.html

UFOSINT. (s. f.). *ufo-dedup* [Repositorio de software y datos]. GitHub. https://github.com/UFOSINT/ufo-dedup

Wall, M. (2016, 28 de julio). *Amazing fireball over western US caused by Chinese space junk*. Live Science. https://www.livescience.com/55585-amazing-fireball-from-chinese-rocket-space-junk-video.html

Anexo A

Diccionario de datos final

La Tabla A1 describe las variables de la tabla de hechos uap_procesado.csv. La versión completa, con las 28 variables desagregadas, se exporta desde el cuaderno como diccionario_datos.csv.

Tabla A1

Diccionario de datos del dataset procesado

Variable	Tipo	Descripción	Origen	Transformación
id	Texto	Identificador único del reporte	Original	Sin cambios
fecha_hora	Fecha-hora	Fecha y hora local del avistamiento	Derivada	Conversión ISO 8601
fecha	Fecha	Fecha del avistamiento	Derivada	Normalización de fecha_hora
hora_conocida	Booleano	1 si el reporte incluía la hora	Derivada	datetime contiene «T»
anio, mes	Entero	Año y mes	Derivada	Extracción de fecha_hora
dia_semana_num, dia_semana	Entero, texto	Día de la semana (1 = lunes)	Derivada	dayofweek + 1
hora	Entero	Hora local (0–23); vacía si no se conoce	Derivada	Hora si hora_conocida
fin_de_semana	Booleano	1 si es sábado o domingo	Derivada	dia_semana_num ≥ 6
franja_dia	Texto	Madrugada, mañana, tarde, noche o sin hora	Derivada	Cortes en 0–5, 6–11, 12–17, 18–23
festivo_pirotecnia	Booleano	1 si es 4 de julio, 31 de diciembre o 1 de enero	Derivada	Regla de calendario
lat, lng	Decimal	Coordenadas de la ciudad	Original	Sin cambios
pais	Texto ISO-3	País del reporte	Original e imputada	Faltantes imputados desde coordenadas
pais_imputado	Booleano	1 si el país fue imputado	Derivada	country nulo
forma_reportada	Texto	Forma original	Original	Nulos como «(nulo)»
forma	Texto	Forma limpia	Derivada	Nulo, unknown y other → desconocida
grupo_forma	Texto	Grupo de forma (6 categorías)	Derivada	Agrupación de 24 formas
duracion_seg_reportada	Decimal	Duración válida declarada (s)	Original	Valores > 24 h → nulo
duracion_seg	Decimal	Duración completa (s)	Derivada	Imputación con mediana por forma
duracion_imputada	Booleano	1 si la duración fue imputada	Derivada	Faltante o atípico

Variable	Tipo	Descripción	Origen	Transformación
duracion_atipica	Booleano	1 si la duración original superaba 24 h	Derivada	durationSec > 86.400
log_duracion	Decimal	log10 de la duración reportada	Derivada	Transformación logarítmica
rango_duracion, rango_duracion_orden	Texto, entero	Rango de duración y su orden	Derivada	Cortes en 59, 300, 900 y 3.600 s
posible_duplicado	Booleano	1 si repite fecha-hora, coordenadas y forma	Derivada	duplicated(keep='first')
cluster_geo	Entero	Segmento geográfico (1–4)	Derivada	K-means sobre lat y lng

Nota. Las variables booleanas se exportan como 0 y 1.

Anexo B

Cuaderno de trabajo y archivos del proyecto

Cuaderno de trabajo: EDA_proyecto_final.ipynb, disponible en https://github.com/danielpaya/eda_entrega_final. Para reproducir los resultados se instalan las dependencias de requirements.txt, se ubica el archivo original en data/raw y se ejecuta el cuaderno completo (Kernel → Restart & Run All).

Archivos entregados: dataset original (data/raw/uap-atlas-reports-2010-2100.csv), dataset procesado y tablas para Power BI (data/processed), figuras (figuras/) y tablero (UAP_Dashboard_CRISP-DM.pbix).

Anexo C

Capturas del tablero de Power BI

Figura C1

Página 1: Resumen del tablero



Nota. Responde la visión general del caso: volumen total, mediana de duración, concentración nocturna y efecto de los festivos con pirotecnia. Fuente: elaboración propia en Power BI.

Figura C2

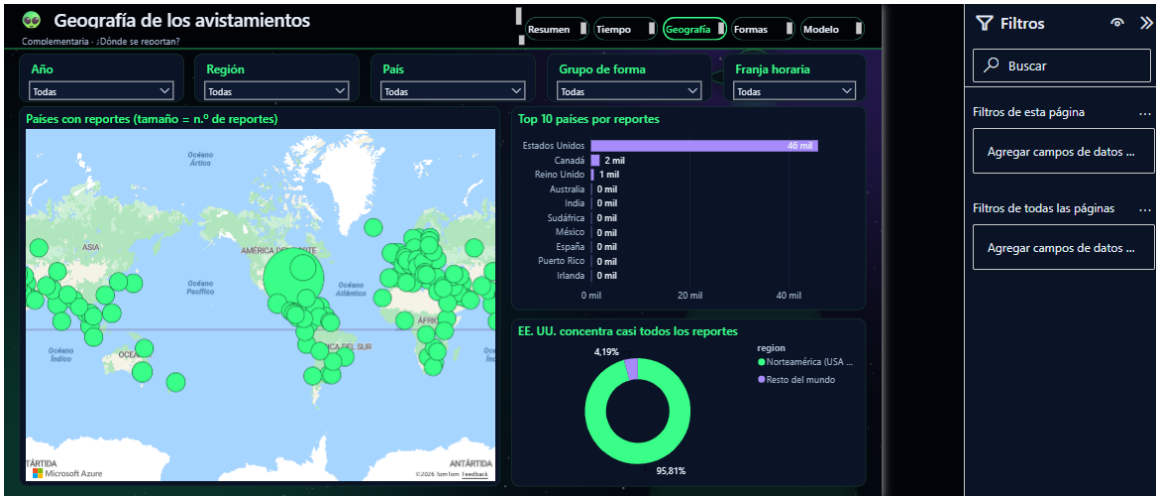
Página 2: Patrones temporales



Nota. Responde la pregunta P1: ¿cuándo se reportan los avistamientos? Fuente: elaboración propia en Power BI.

Figura C3

Página 3: Geografía de los avistamientos



Nota. Complementa el análisis con la pregunta: ¿dónde se reportan? Fuente: elaboración propia en Power BI.

Figura C4

Página 4: Formas y duración



Nota. Responde la pregunta P2: ¿qué se ve y cuánto dura? Fuente: elaboración propia en Power BI.

Figura C5

Página 5: Modelo de pronóstico



Nota. Responde la pregunta P3: ¿se puede pronosticar el volumen mensual de reportes? Fuente: elaboración propia en Power BI.